

기존 방법론 조사

📅 시작일	@08/26/2025
📅 종료일	@08/31/2025
# 시작 값	10
# 종료 값	100
📊 진행 상황	10%
🕒 우선순위	높음
👤 담당자	Ⓜ 고승호
🌟 상태	완료

프로젝트 목표

- Imbalanced Data를 다루는 기존 방법에 대해 공식, 기본적인 이론 알아보기
- 공식이 어렵지 않다면 수식이 의미하는 바에 대해 생각해보고 추가할 것.
- 결과적으로 Adaptive Class-Weighted Cross Entropy Loss, Power-Scaled-Weighted Cross Entropy, Power-Scaled-Weighted-Inverse Cross Entropy 의 사용을 주장해야 하기 때문에 기존 방법과의 차이점을 각각 정리해야 함.

문서

[Class-Balanced Loss Based on Effective Number of Samples.pdf](#)

[Focal Loss for Dense Object Detection.pdf](#)

[Resolving Class Imbalance in Object Detection with Weighted Cross Entropy Losses.pdf](#)

정리

1.1 기초적 접근법: 가중 교차 엔트로피(WCE) 및 균형 교차 엔트로피(BCE)

A. 개념 소개

가중 교차 엔트로피(Weighted Cross-Entropy, WCE)는 클래스 불균형 문제를 해결하기 위한 가장 직관적이고 기본적인 접근법 중 하나이다. 이는 비용 민감 학습(cost-sensitive learning)의 원리를 교차 엔트로피 손실 함수에 직접 적용한 것이다. 비용 민감 학습의 핵심 가정은 모든 오분류(misclassification)의 비용이 동일하지 않다는 것이다. 특히 불균형 데이터셋에서는 소수 클래스를 잘못 분류하는 것(예: 암 환자를 정상으로 진단)이 다수 클래스를 잘못 분류하는 것(예: 정상인을 암 환자로 진단)보다 훨씬 더 큰 비용을 초래하는 경우가 많다. WCE는 이러한 비대칭적 비용을 모델 학습에 반영하기 위해, 각 클래스의 손실 값에 서로 다른 가중치(weight)를 부여한다. 구체적으로 소수 클래스의 오분류에는 높은 가중치를, 다수 클래스의 오분류에는 낮은 가중치를 할당하여 모델이 상대적으로 적은 수의 소수 클래스 샘플을 더 중요하게 학습하도록 유도한다.

균형 교차 엔트로피(Balanced Cross-Entropy, BCE)는 WCE의 가장 일반적인 구현 형태이다. BCE에서는 클래스별 가중치를 해당 클래스의 샘플 수(빈도)에 반비례하도록 설정한다. 즉, 샘플 수가 적은 소수 클래스일수록 더 높은 가중치를 부여받게 되어, 학습 과정에서 소수 클래스의 영향력이 자연스럽게 증폭된다. 이 방식은 별도의 비용 행렬(cost matrix)을 정의할 필요 없이 데이터의 통계적 특성만으로 가중치를 결정할 수 있어 널리 사용된다.

B. 수학적 공식

먼저, 다중 클래스 분류 문제에서 표준 교차 엔트로피(Standard Cross-Entropy, CE) 손실은 다음과 같이 정의된다.

$$L_{CE}(y, \hat{y}) = - \sum_{i=1}^C y_i \log(\hat{y}_i)$$

여기서 변수들은 다음과 같이 정의된다.

- C : 전체 클래스의 수
- y_i : 클래스 i 에 대한 실제 레이블 (일반적으로 원-핫 인코딩 벡터의 i 번째 요소로, 정답 클래스일 경우 1, 아닐 경우 0)
- $\hat{y}_i$: 모델이 예측한 클래스 i 에 대한 확률

가중 교차 엔트로피(WCE)는 이 표준 공식에 클래스별 가중치 w_i 를 추가하여 다음과 같이 정의된다.

$$L_{WCE}(y, \hat{y}) = - \sum_{i=1}^C w_i \cdot y_i \log(\hat{y}_i)$$

- w_i : 클래스 i에 할당된 가중치. 이 값이 클수록 해당 클래스의 손실이 전체 손실에 더 큰 영향을 미친다.

균형 교차 엔트로피(BCE)는 WCE의 특수한 경우로, 가중치 w_i 를 클래스 빈도의 역수 (inverse class frequency)로 설정한다. 가중치를 계산하는 일반적인 방식은 다음과 같다.

$$w_i = N/n_i$$

- N : 전체 훈련 샘플의 수
- n_i : 클래스 i에 속하는 훈련 샘플의 수

이 방식을 사용하면, 모든 클래스의 가중치를 고려한 총합이 클래스 수와 유사하게 되어 학습의 안정성을 돕는다. 때로는 $w_i = 1/n_i$ 와 같이 더 단순한 형태로 정규화 없이 사용되기도 한다.

C. 메커니즘 및 주요 차이점 분석

WCE와 BCE의 불균형 처리 메커니즘은 정적 가중치 할당(static weight assignment)에 기반한다. 이는 모델 학습이 시작되기 전에 전체 훈련 데이터셋의 클래스 분포를 분석하여 각 클래스에 대한 가중치를 미리 계산하고, 이 가중치를 학습 과정 내내 고정적으로 적용하는 방식이다. 모델이 경사 하강법(gradient descent)을 통해 파라미터를 업데이트할 때, 소수 클래스 샘플에서 계산된 손실 값은 높은 가중치(w_i)에 의해 증폭된다. 결과적으로, 소수 클래스 샘플에 대한 그래디언트(gradient)의 크기가 상대적으로 커져 파라미터 업데이트에 더 큰 영향력을 행사하게 된다. 이는 모델이 다수 클래스의 손실을 줄이는 것보다 소수 클래스의 손실을 줄이는 것에 더 집중하도록 만드는 효과를 낳는다.

제안된 "적응형 클래스 가중 교차 엔트로피 손실" 함수는 이러한 정적 가중치 할당 메커니즘을 공유한다는 점에서 WCE/BCE와 유사하다. 두 방식 모두 클래스별 샘플 수(n_i)라는 데이터의 정적 통계량을 기반으로 가중치를 결정한다.

그러나 핵심적인 차이점은 가중치를 계산하는 함수 형태에 있다.

- **BCE 가중치:** $w_i \propto 1/n_i$ 로, 가중치는 샘플 수에 정비례하여 감소한다. 이는 샘플 수가 두 배가 되면 가중치는 절반으로 줄어드는 선형적인 관계를 의미한다.
- **제안된 함수 가중치:** $w_i = \frac{1}{\log(1+n_i)}$ 로, 가중치는 샘플 수의 로그 값에 반비례한다.

이러한 함수 형태의 차이는 중요한 함의를 가진다. BCE의 $1/n_i$ 가중치 방식은 클래스 불균형이 극심한 경우, 예를 들어 다수 클래스가 소수 클래스보다 100배 이상 많은 경우, 소수 클래스에 매우 큰 가중치를, 다수 클래스에 매우 작은 가중치를 부여하게 된다. 일부 연구에서는 이러한 극단적인 가중치 할당이 오히려 모델 성능을 저하시킬 수 있다고 지적한다. 이는 모델이 극소수의 샘플에서 발생하는 거대한 손실 값을 줄이는 데에만 과도하게 집중하게 만들어 소수 클래스에 대한 과적합(overfitting)을 유발할 수 있기 때문이다. 즉, 모델이 소수

클래스의 특정 샘플들만 암기하게 되어 새로운 데이터에 대한 일반화 성능이 떨어질 수 있다.

반면, 제안된 함수의 로그 기반 가중치($1/\log(1 + n_i)$)는 이러한 문제를 완화할 잠재력을 가진다. 로그 함수의 특성상, 입력값(n_i)이 증가함에 따라 함수 값의 증가율은 점차 둔화된다. 역수를 취하면, 샘플 수(n_i)가 증가할 때 가중치의 감소율이 $1/n_i$ 방식보다 훨씬 완만해진다. 이는 다수 클래스의 영향력을 과도하게 억제하지 않으면서 소수 클래스의 중요도를 높이는, 일종의 규제(regularization) 효과를 가져온다. 즉, 제안된 가중치 체계는 BCE의 극단적인 가중치 할당을 완화하여, 극심한 불균형 상황에서도 더 안정적인 학습을 가능하게 할 수 있다.

D. 대표 논문 및 실험 결과

WCE와 BCE는 특정 단일 논문에서 창시되었다기보다는, 비용 민감 학습 분야에서 자연스럽게 발전해 온 기초적인 방법론이다. 따라서, 이 기법들을 베이스라인(baseline)으로 사용하여 다른 방법론과 비교한 연구를 참조하는 것이 그 효과를 이해하는 데 도움이 된다.

- **대표 연구:** Wang 등(2019)은 고객 이탈 예측(churn prediction) 문제에서 비용 민감 학습 접근법의 효과를 평가하며 WCE를 주요 방법론 중 하나로 사용했다.
- **실험 설정:**
 - **데이터셋:** 통신사 고객 이탈 예측과 관련된 실제 산업 데이터셋을 사용했다. 이 데이터셋은 이탈 고객(소수 클래스)과 비이탈 고객(다수 클래스) 간의 심각한 불균형을 특징으로 한다.
 - **비교 대상:** WCE와 같은 비용 민감 학습 방법론을 SMOTE(Synthetic Minority Over-sampling Technique)와 같은 데이터 리샘플링 방법론과 비교했다.
 - **평가 지표:** 클래스 불균형 문제에서 정확도(accuracy)보다 더 신뢰성 있는 지표로 알려진 AUC(Area Under the ROC Curve)를 사용하여 모델 성능을 평가했다.
- **성능 결과:** 해당 연구에서는 WCE와 Focal Loss를 포함한 비용 민감 학습 방법들이 SMOTE와 같은 데이터 리샘플링 방법에 비해 전반적으로 더 우수한 예측 성능(더 높은 AUC 값)을 보였다고 보고했다. 이는 데이터 자체를 변경하는 것보다, 학습 알고리즘 내에서 손실 함수를 통해 클래스 중요도를 조절하는 방식이 특정 문제(고객 이탈 예측)에서 더 효과적일 수 있음을 시사한다.

1.2 Focal Loss: 어려운 예제에 집중하기

A. 개념 소개

Focal Loss는 클래스 불균형 문제를 바라보는 새로운 관점을 제시하며 큰 주목을 받은 손실 함수이다. 이 손실 함수의 핵심 아이디어는, 클래스 불균형이 야기하는 진짜 문제는 단순히

소수 클래스의 샘플 수가 적다는 점이 아니라, 학습 과정에서 압도적인 수를 차지하는 '쉽게 분류되는(well-classified)' 다수 클래스 샘플들이 만들어내는 손실 값의 총합이 모델 학습을 지배한다는 통찰에서 출발한다. 예를 들어, 배경(다수 클래스)과 객체(소수 클래스)를 탐지하는 문제에서, 대부분의 배경 영역은 모델이 매우 쉽게 '배경'이라고 예측할 수 있다. 개별적인 쉬운 샘플(easy example)이 생성하는 손실 값은 매우 작지만, 그 수가 수만, 수십만에 달하면 이 작은 손실 값들이 합쳐져 전체 손실의 대부분을 차지하게 된다. 이로 인해 모델의 파라미터 업데이트는 주로 이 쉬운 샘플들의 손실을 줄이는 데 사용되며, 정작 중요하게 학습해야 할 어려운 샘플(hard examples, 예: 소수 클래스 샘플 또는 잘못 분류된 샘플)에 대한 학습은 제대로 이루어지지 않는다.

Focal Loss는 이 문제를 해결하기 위해 표준 교차 엔트로피 손실에 조절 계수(modulating factor)라는 동적인 스케일링 항을 도입한다. 이 조절 계수는 모델이 특정 샘플을 얼마나 확신을 가지고 올바르게 예측하는지에 따라 손실 값의 크기를 조절한다. 모델이 이미 잘 분류하고 있는 쉬운 예제에 대해서는 손실 기여도를 크게 낮추고, 분류하기 어려운 예제에 대해서는 손실을 거의 그대로 유지함으로써, 모델이 자연스럽게 어려운 예제에 학습 역량을 집중하도록 유도한다.

B. 수학적 공식

Focal Loss는 이진 분류 문제에 대한 교차 엔트로피를 기반으로 다음과 같이 정의된다.

$$L_{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

여기서 각 변수는 다음과 같이 정의된다.

- p_t : 정답 클래스에 대한 모델의 예측 확률을 나타낸다.
 - 실제 레이블 $y = 1$ 일 때, $p_t = p$ (모델이 클래스 1로 예측한 확률)
 - 실제 레이블 $y = 0$ 일 때, $p_t = 1 - p$ (모델이 클래스 0으로 예측한 확률)
- γ (감마): **집중 파라미터(focusing parameter)**로, $\gamma \geq 0$ 의 값을 가진다. 이 값이 클수록 쉬운 예제의 손실 기여도를 더 급격하게 감소시키는 효과가 있다. $\gamma = 0$ 일 경우, 조절 계수 $(1 - p_t)^0 = 1$ 이 되어 Focal Loss는 표준 교차 엔트로피와 동일해진다. 논문에서는 $\gamma = 2$ 일 때 가장 좋은 성능을 보였다고 보고했다.
- α_t (알파): **균형 파라미터(balancing parameter)**로, WCE/BCE의 가중치 w_i 와 유사한 역할을 한다. 이는 클래스 불균형을 직접적으로 다루기 위한 정적 가중치이다. 예를 들어, 클래스 1에 대해서는 α , 클래스 0에 대해서는 $1 - \alpha$ 를 할당할 수 있다. 이 파라미터는 γ 와 함께 사용되어 성능을 더욱 향상시킨다.

C. 메커니즘 및 주요 차이점 분석

Focal Loss의 불균형 처리 메커니즘은 동적, 샘플 단위 가중치 조절(dynamic, sample-wise weight modulation)에 기반한다. 이는 WCE/BCE나 제안된 손실 함수의 정적, 클래스 단위 가중치 방식과 근본적인 차이를 보인다.

Focal Loss의 가중치는 클래스 빈도와 같은 정적인 속성이 아니라, 각 개별 샘플에 대한 모델의 예측 확신도(p_t)에 따라 학습 과정 중에 실시간으로 변한다.

- **쉬운 예제 ($p_t \rightarrow 1$):** 모델이 정답을 거의 확신하는 경우, 조절 계수인 $(1 - p_t)\gamma$ 는 0에 매우 가까워진다. 예를 들어, $p_t = 0.9$ 이고 $\gamma = 2$ 이면, 가중치는 $(1 - 0.9)^2 = 0.01$ 로 줄어들어 해당 샘플의 손실이 $1/100$ 로 감소한다.
- **어려운 예제 ($p_t \rightarrow 0$):** 모델이 정답을 거의 확신하지 못하고 틀리는 경우, 조절 계수인 $(1 - p_t)\gamma$ 는 1에 가까워진다. 예를 들어, $p_t = 0.1$ 이고 $\gamma = 2$ 이면, 가중치는 $(1 - 0.1)^2 = 0.81$ 로, 손실이 거의 그대로 유지된다.

이러한 메커니즘은 제안된 "적응형 클래스 가중 교차 엔트로피 손실"과 다음과 같은 근본적인 차이점을 가진다.

- **문제 정의의 차이:** 제안된 함수는 '클래스 간의 샘플 수 불균형'을 직접적인 문제로 정의하고 이를 해결하려 한다. 반면, Focal Loss는 '쉬운 예제와 어려운 예제 간의 학습 기여도 불균형'을 문제로 정의하고, 이를 해결함으로써 간접적으로 클래스 불균형 문제를 완화한다. 다수 클래스에 속한 샘플들이 대체로 '쉬운 예제'일 가능성이 높기 때문에 이 접근법이 효과를 발휘한다.
- **가중치 부여의 대상:** 제안된 함수는 '클래스'라는 집단에 가중치를 부여한다. 해당 클래스에 속한 모든 샘플은 동일한 가중치를 적용받는다. Focal Loss는 '개별 샘플'에 가중치를 부여한다. 같은 클래스에 속한 샘플이라도 모델의 예측 결과에 따라 서로 다른 가중치를 가질 수 있다.

D. 창시 논문 및 실험 결과

- **창시 논문:** Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE international conference on computer vision*.
- **실험 설정:**
 - **주요 과제:** 이 논문은 1단계 객체 탐지기(one-stage object detector)의 성능을 개선하는 것을 목표로 했다. 1단계 탐지기는 속도가 빠르지만, 이미지 내에서 객체가 없는 배경 영역(다수 클래스)과 실제 객체(소수 클래스) 간의 극심한 클래스 불균형으로 인해 2단계 탐지기(two-stage detector)보다 정확도가 낮은 문제를 겪고 있었다.

- **모델:** 저자들은 Focal Loss의 효과를 입증하기 위해 RetinaNet이라는 새로운 1단계 탐지기 아키텍처를 설계하고 제안했다.
- **데이터셋:** 대규모 객체 탐지 벤치마크 데이터셋인 MS COCO를 사용했다.
- **비교 대상:** 당시 최신 기술이었던 OHEM(Online Hard Example Mining)과 같은 하드 샘플 마이닝 기법 및 표준 교차 엔트로피를 사용한 모델들과 성능을 비교했다.
- **성능 결과:** Focal Loss를 사용하여 학습된 RetinaNet은 기존의 1단계 탐지기들의 빠른 속도를 유지하면서도, 더 복잡하고 느린 2단계 탐지기들의 정확도(AP, Average Precision)를 능가하는 당시 최고 수준(State-of-the-Art, SOTA)의 성능을 달성했다. 이 결과는 Focal Loss가 극심한 클래스 불균형 상황에서 모델이 중요한 정보에 집중하도록 만드는 데 매우 효과적임을 실증적으로 입증했으며, 이후 객체 탐지뿐만 아니라 다양한 불균형 데이터 문제에 널리 적용되는 계기가 되었다.

1.3 클래스 균형 손실 (Class-Balanced Loss)

A. 개념 소개

클래스 균형 손실(Class-Balanced Loss, CB Loss)은 클래스 불균형 문제를 해결하기 위해 데이터의 본질적인 구조를 더 깊이 고려하는 접근법을 제안한다. 이 방법론의 핵심 아이디어는, 다수 클래스에 샘플 수가 많아질수록 새로 추가되는 데이터가 제공하는 추가적인 정보의 가치, 즉 한계 이득(marginal benefit)이 점차 감소한다는 개념에서 출발한다. 이는 특정 클래스 내에 데이터가 많아질수록 샘플들 간의 중복(overlap)이나 유사성이 증가하여, 단순히 샘플 수를 세는 것만으로는 해당 클래스가 가진 정보의 총량을 정확히 반영하기 어렵다는 통찰에 기반한다.

이 문제를 해결하기 위해, CB Loss는 '유효 샘플 수(effective number of samples)'라는 새로운 개념을 도입한다. 유효 샘플 수는 특정 클래스의 데이터 샘플들이 차지하는 특징 공간(feature space)의 실제 볼륨(volume)으로 정의되며, 데이터 중복을 고려하여 계산된다. 즉, 샘플 수가 아무리 많아도 특징 공간 상에서 서로 겹치는 부분이 많다면 유효 샘플 수는 실제 샘플 수보다 훨씬 작게 측정된다. CB Loss는 손실 함수에 적용할 가중치를 단순한 샘플 수의 역수가 아닌, 이 유효 샘플 수의 역수에 비례하도록 설정한다. 이를 통해, 데이터가 풍부한 다수 클래스의 영향력을 보다 정교하게 조절하고, 소수 클래스에 효과적으로 가중치를 부여한다.

B. 수학적 공식

CB Loss의 핵심은 유효 샘플 수(E_n)를 계산하는 것이다. 특정 클래스에 n 개의 샘플이 있을 때, 유효 샘플 수는 다음과 같은 공식으로 모델링된다.

$$E_n = \frac{1-\beta^n}{1-\beta}$$

여기서 각 변수는 다음과 같이 정의된다.

- n : 해당 클래스의 실제 샘플 수.
- β : 데이터의 중복 정도를 모델링하는 하이퍼파라미터로, $0 \leq \beta < 1$ 의 값을 가진다. β 는 $(N - 1)/N$ 으로 정의될 수 있으며, 여기서 N 은 해당 클래스의 잠재적인 전체 데이터 볼륨 또는 고유한 프로토타입의 수를 의미한다. β 가 0에 가까우면 샘플 간 중복이 심하다고 가정하며($E_n = 1$), β 가 1에 가까우면 샘플 간 중복이 적다고 가정하여 E_n 이 n 에 가까워진다.

이 유효 샘플 수를 사용하여, 클래스 균형 손실(CB Loss)은 기존 손실 함수 $L(p, y)$ 에 가중치를 적용하는 형태로 정의된다.

$$L_{CB}(p, y) = \frac{1}{E_{n_y}} \cdot L(p, y) = \frac{1-\beta}{1-\beta^{n_y}} \cdot L(p, y)$$

- n_y : 정답 레이블 y 에 해당하는 클래스의 샘플 수.
- $L(p, y)$: 기반이 되는 손실 함수로, Softmax Cross-Entropy, Sigmoid Cross-Entropy, Focal Loss 등 다양한 손실 함수와 결합하여 사용할 수 있다.

C. 메커니즘 및 주요 차이점 분석

CB Loss의 불균형 처리 메커니즘은 **유효 샘플 수를 통한 정교한 정적 가중치 조절**에 기반한다. 이는 BCE와 마찬가지로 클래스 단위의 정적 가중치를 사용하지만, 가중치를 계산하는 방식이 이론적 프레임워크에 기반하여 더욱 정교하다. 하이퍼파라미터 β 를 통해 데이터셋의 특성(예: 클래스 내 분산, 데이터의 다양성)에 맞춰 가중치의 감쇠율을 유연하게 조절할 수 있다는 장점이 있다.

제안된 "적응형 클래스 가중 교차 엔트로피 손실" 함수와 비교하면 다음과 같은 차이점이 있다.

- **수학적 형태와 이론적 기반**: 제안된 함수는 $1/\log(1 + n_i)$ 라는 비교적 단순하고 직관적인 로그 형태의 휴리스틱을 사용한다. 반면, CB Loss는 데이터 샘플링 공간의 볼륨과 중복이라는 명확한 이론적 프레임워크에 기반한 지수 형태의 가중치($1/(1 - \beta n)$)를 사용한다. 이는 CB Loss가 더 원론적인 접근법임을 시사한다.
- **하이퍼파라미터 의존성**: CB Loss의 성능은 하이퍼파라미터 β 의 설정에 크게 의존한다. 데이터셋의 특성에 맞는 최적의 β 를 찾기 위한 추가적인 튜닝 과정이 필요하다. 반면, 제안된 함수는 별도의 하이퍼파라미터가 없어 사용이 간편하고, 추가적인 튜닝 없이 바로 적용할 수 있다는 실용적인 장점을 가진다.

D. 창시 논문 및 실험 결과

- **창시 논문**: Cui, Y., Jia, M., Lin, T. Y., Song, Y., & Belongie, S. (2019). Class-balanced loss based on effective number of samples. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*.

- **실험 설정:**

- **데이터셋:** 저자들은 제안된 손실 함수의 효과를 광범위하게 검증하기 위해, 인위적으로 긴 꼬리 분포(long-tailed distribution)를 생성한 CIFAR-10-LT, CIFAR-100-LT 데이터셋과, 실제 세계의 대규모 불균형 데이터셋인 iNaturalist 및 ImageNet을 사용했다.
- **평가 방법:** CB 가중치 항을 Softmax Cross-Entropy, Sigmoid Cross-Entropy, Focal Loss와 같은 기존의 여러 손실 함수와 결합하여, 원래의 손실 함수와 성능을 직접 비교했다.
- **성능 결과:** 실험 결과, 모든 벤치마크 데이터셋에서 기존 손실 함수에 CB 가중치를 적용했을 때 일관되게 성능이 향상되었다. 특히, 불균형 정도가 매우 심한 iNaturalist 데이터셋에서 CB Loss와 Focal Loss를 결합한 'CB Focal' 손실 함수가 상당한 성능 향상(분류 오류율 감소)을 보이며 그 효과를 입증했다. 이는 유효 샘플 수라는 개념이 실제 데이터의 정보량을 더 잘 반영하여 효과적인 재조정(re-balancing)을 가능하게 함을 보여준다.

1.4 레이블 분포 인식 마진 손실 (Label-Distribution-Aware Margin Loss, LDAM)

A. 개념 소개

레이블 분포 인식 마진 손실(Label-Distribution-Aware Margin Loss, LDAM)은 클래스 불균형 문제를 해결하기 위해 기존의 손실 값 재조정(re-weighting) 패러다임에서 벗어나, 모델이 학습하는 특징 공간의 기하학적 구조에 직접 개입하는 혁신적인 접근법을 제시한다. LDAM의 핵심 아이디어는, 소수 클래스의 일반화 성능을 높이기 위해서는 모델의 **결정 경계(decision boundary)**와 **소수 클래스 샘플들 간의 마진(margin)**을 더 크게 만들어야 한다는 것이다. 마진이 크다는 것은 모델이 해당 클래스를 더 확신을 가지고, 다른 클래스와 명확하게 구분하여 예측한다는 것을 의미한다.

기존의 re-weighting 방식들이 손실 계산 단계에서 산술적으로 가중치를 곱하는 방식을 사용했다면, LDAM은 손실 함수 자체에 클래스별로 다른 크기의 마진을 명시적으로 포함시킨다. 구체적으로, 클래스별 샘플 수에 반비례하는 마진을 설정하여, 샘플 수가 적은 소수 클래스일수록 더 큰 마진을 갖도록 강제한다. 이는 일종의 레이블 의존적 규제(label-dependent regularization)로 작용하여, 모델이 소수 클래스에 대해 더 강건한(robust) 표현을 학습하도록 유도한다.

B. 수학적 공식

LDAM Loss는 Softmax Cross-Entropy 손실을 마진을 포함하도록 수정한 형태이다. 모델의 로짓(logit) 출력을 $z = (z_1, \dots, z_C)$ 라고 할 때, 정답 클래스 y 에 대한 LDAM Loss는 다음과 같이 정의된다.

$$L_{\text{LDAM}}(z, y) = -\log \left(\frac{e^{z_y - \Delta_y}}{e^{z_y - \Delta_y} + \sum_{j \neq y} e^{z_j}} \right)$$

여기서 핵심적인 부분은 클래스별 마진 Δ_j 이며, 이는 다음과 같이 계산된다.

$$\Delta_j = \frac{C}{n_j^{1/4}}$$

- z_j : 모델의 j-번째 클래스에 대한 로짓 출력.
- n_j : 클래스 j에 속하는 훈련 샘플의 수.
- C : 마진의 전체적인 크기를 조절하는 하이퍼파라미터. C 가 클수록 마진이 커진다.

이 공식에서 z_y 에서 Δ_y 를 빼주는 항이 핵심이다. 손실을 최소화하기 위해 모델은 $e^{z_y - \Delta_y}$ 값을 키워야 하는데, 이는 결국 z_y 를 다른 클래스의 로짓 z_j 보다 Δ_y 만큼 더 크게 만들어야 함을 의미한다. n_y 가 작을수록 Δ_y 가 커지므로, 소수 클래스에 대해 더 큰 마진을 확보하도록 유도된다.

C. 메커니즘 및 주요 차이점 분석

LDAM의 불균형 처리 메커니즘은 결정 경계 조정(decision boundary adjustment)에 기반한다. 이는 손실 값 자체의 크기를 조절하는 것이 아니라, 올바른 클래스의 로짓 값에서 클래스별 마진을 빼줌으로써 모델이 소수 클래스에 대해 더 '자신감 있는' 예측(즉, 다른 클래스와의 로짓 값 차이가 큰 예측)을 하도록 강제하는 방식이다.

이러한 접근 방식은 WCE, CB Loss, 그리고 제안된 손실 함수와 같은 re-weighting 기법들과 근본적인 차이를 보인다. WCE 계열의 손실 함수들이 학습 과정에서 발생하는 오차에 대한 '벌점'을 산술적으로 조정하는 방식이라면, LDAM은 모델이 학습해야 할 '목표' 자체를 기하학적으로 변경하는 방식이다. 이는 단순히 "이 샘플의 오차를 얼마나 중요하게 볼 것인가?"라는 질문에서 "이 클래스의 결정 경계는 다른 클래스로부터 얼마나 멀리 떨어져야 하는가?"라는 질문으로의 전환을 의미한다.

이러한 개념적 전환은 매우 중요하다. 이는 손실 값을 단순히 재조정하는 것만으로는 근본적인 한계가 있을 수 있으며, 학습된 분류기의 기하학적 속성(즉, 마진)을 직접 수정하는 것이 더 강력하고 보완적인 접근법이 될 수 있음을 시사한다. 제안된 손실 함수는 BCE의 단점을 개선하는 효과적인 방법일 수 있지만, 여전히 re-weighting이라는 전통적인 패러다임 내에 있다.

또한, LDAM의 마진 조정 메커니즘은 re-weighting 기법과 이론적으로 직교(orthogonal)하기 때문에 두 가지를 함께 사용할 수 있다. 실제로 LDAM 논문에서는 DRW(Deferred Re-Weighting)라는, 학습 초기에는 re-weighting 없이 일반적인 표현을 학습하고 후반부에 re-weighting을 적용하여 미세 조정하는 훈련 스케줄링 기법과 LDAM을 결합하여 당시 최고 수준의 성능을 달성했다.

D. 창시 논문 및 실험 결과

- **참시 논문:** Cao, K., Wei, C., Gaidon, A., Arechiga, N., & Ma, T. (2019). Learning imbalanced datasets with label-distribution-aware margin loss. *Advances in neural information processing systems*, 32.
- **실험 설정:**
 - **핵심 제안:** LDAM Loss와 함께, 학습 스케줄에 따라 re-weighting의 강도를 조절하는 **DRW(Deferred Re-Weighting)** 훈련 스케줄을 함께 제안했다. 이 전략은 학습 초기에는 모델이 과적합 없이 데이터의 전반적인 특징을 학습하도록 돕고, 학습 후반부에 소수 클래스에 집중하여 성능을 극대화한다.
 - **데이터셋:** 인위적으로 불균형을 만든 CIFAR-10/100 데이터셋과 실제 대규모 불균형 데이터셋인 iNaturalist 2018 등을 사용하여 광범위한 실험을 수행했다.
- **성능 결과:** LDAM과 DRW를 결합한 LDAM-DRW 방법은 당시의 모든 벤치마크 데이터셋에서 최고 수준의 성능을 달성했다. 특히, 매우 도전적인 iNaturalist 2018 데이터셋에서 기존의 최고 성능 모델이었던 CB Focal Loss 대비 Top-1 오류율을 약 7%p 가량 큰 폭으로 개선하며, 마진 기반 접근법의 강력한 효과를 입증했다. 이 결과는 클래스 불균형 문제 해결 연구의 방향을 새로운 차원으로 이끄는 중요한 성과로 평가받는다.

1.5 그래디언트 조화 메커니즘 손실 (Gradient Harmonized Mechanism Loss, GHM)

A. 개념 소개

그래디언트 조화 메커니즘 손실(Gradient Harmonized Mechanism Loss, GHM)은 Focal Loss와 유사하게 쉬운 예제와 어려운 예제 간의 불균형 문제에 주목하지만, 이를 '그래디언트 분포의 부조화(disharmony in gradient distribution)'라는 새로운 관점에서 접근한다. GHM의 핵심 아이디어는, 학습 과정에서 전체 그래디언트의 합이 소수의 어려운 예제나 다수의 쉬운 예제에 의해 지배되는 현상이 문제의 본질이라는 것이다.

Focal Loss는 개별 샘플의 예측 확률(pt)만을 보고 가중치를 결정하지만, GHM은 한 걸음 더 나아가 미니배치(mini-batch) 내의 전체 샘플들의 그래디언트 분포를 고려한다. 구체적으로, 각 샘플의 그래디언트 크기(norm)를 계산하고, 비슷한 그래디언트 크기를 갖는 샘플들이 얼마나 많은지, 즉 '그래디언트 밀도(gradient density)'를 측정한다. 만약 특정 그래디언트 크기 구간에 샘플들이 과도하게 몰려 있다면(밀도가 높다면), 이는 해당 유형의 샘플들이 전체 그래디언트에 불균형적으로 큰 영향을 미치고 있음을 의미한다. GHM은 이 밀도에 반비례하는 가중치를 각 샘플에 부여하여, 밀도가 높은 구간의 샘플들(주로 매우 쉬운 예제들)의 영향력을 낮추고, 밀도가 낮은 구간의 샘플들(중간 난이도의 중요한 예제들)의 영향력을 상대적으로 높여 전체 그래디언트 기여도를 조화롭게 만든다.

B. 수학적 공식

GHM은 분류 손실(GHM-C)과 회귀 손실(GHM-R) 두 가지 형태로 제안되었다. 여기서는 분류 손실인 GHM-C를 중심으로 설명한다.

$$L_{\text{GHM-C}} = \frac{1}{N} \sum_{i=1}^N \beta_i L_{\text{CE}}(p_i, p_i^*) = \sum_{i=1}^N \frac{L_{\text{CE}}(p_i, p_i^*)}{GD(g_i)}$$

여기서 각 변수는 다음과 같이 정의된다.

- $LCE(p_i, p_i^*)$: i -번째 샘플에 대한 표준 교차 엔트로피 손실.
- $g = |p - p^*|$: 그래디언트 norm. 모델의 예측 확률 p 와 실제 레이블 p^* 간의 절대적인 차이로, 샘플의 난이도를 나타내는 지표로 사용된다.
- $GD(g)$: 그래디언트 norm g 를 갖는 예제들의 밀도 함수. 특정 그래디언트 값 g 주변의 단위 길이 당 샘플 수를 나타낸다.
- $\beta_i = \frac{N}{GD(g_i)}$: **그래디언트 밀도 조화 파라미터**. i -번째 샘플의 그래디언트 밀도 $GD(g_i)$ 에 반비례하는 가중치이다.

C. 메커니즘 및 주요 차이점 분석

GHM의 불균형 처리 메커니즘은 **미니배치 단위의 동적 그래디언트 밀도 기반 가중치 조절**에 기반한다. 이는 학습 중인 각 미니배치의 동적인 그래디언트 분포를 실시간으로 분석하여 가중치를 적응적으로 결정하는 방식이다. 이 메커니즘은 Focal Loss보다 더 정교하다. Focal Loss는 샘플이 쉽다($pt \rightarrow 1$)는 이유만으로 가중치를 낮추지만, GHM은 해당 샘플과 비슷한 난이도를 가진 다른 샘플들이 얼마나 많은지를 함께 고려하여 가중치를 상대적으로 조절한다. 예를 들어, 어떤 어려운 샘플이 이상치(outlier)처럼 다른 샘플들과 매우 다른 그래디언트 값을 가진다면, 그 밀도가 낮기 때문에 가중치가 오히려 낮아져 학습 안정성에 기여할 수 있다.

제안된 "적응형 클래스 가중 교차 엔트로피 손실" 함수와의 비교는 다음과 같다.

- **정적 vs. 동적**: 제안된 함수는 전체 데이터셋의 정적인 속성(클래스별 샘플 수)을 사용한다. 반면, GHM은 학습이 진행됨에 따라 모델의 예측 능력이 변하고, 그에 따라 미니배치마다 달라지는 동적인 속성(그래디언트 분포)을 사용한다.
- **정보의 원천**: 제안된 함수는 오직 레이블 정보(n_i)만을 사용하여 가중치를 결정한다. GHM은 모델의 예측(p)과 실제 레이블(p^*) 정보를 모두 사용하여 그래디언트를 계산하고, 이를 기반으로 가중치를 결정하므로 더 풍부한 정보를 활용한다.
- **처리 대상의 범위**: 제안된 함수는 클래스 간의 불균형에만 초점을 맞춘다. GHM은 그래디언트 밀도라는 단일 프레임워크를 통해 (1) 쉬운 예제와 어려운 예제 간의 불균형, (2) 긍정 예제와 부정 예제 간의 불균형, 그리고 (3) 이상치(outlier) 문제를 동시에 조화롭게 처리할 수 있는 더 일반적인 메커니즘이다.

D. 창시 논문 및 실험 결과

- **창시 논문:** Li, B., Liu, Y., & Wang, X. (2019). Gradient harmonized single-stage detector. *Proceedings of the AAAI conference on artificial intelligence*, 33(01).
- **실험 설정:**
 - **주요 과제:** Focal Loss와 마찬가지로, 1단계 객체 탐지기에서의 클래스 불균형 문제를 해결하는 것을 목표로 했다.
 - **모델 및 데이터셋:** Focal Loss 논문과 동일하게 RetinaNet 아키텍처와 MS COCO 벤치마크 데이터셋을 사용하여 직접적인 성능 비교를 수행했다.
 - **비교 대상:** 주요 비교 대상은 Focal Loss였다.
- **성능 결과:** 실험 결과, GHM을 적용한 모델은 MS COCO test-dev 셋에서 41.6 mAP를 달성하여, Focal Loss를 적용한 모델(40.8 mAP)보다 0.8 mAP 더 높은 성능을 기록했다. 이 결과는 GHM이 Focal Loss의 정적인 하이퍼파라미터(α, γ) 튜닝의 어려움을 해결하고, 학습 데이터의 분포에 더 효과적으로 적응하는 동적 메커니즘임을 시사한다. GHM은 별도의 하이퍼파라미터 튜닝 없이도 안정적으로 우수한 성능을 보였다.

1.6 손실 함수 종합 및 비교 분석

지금까지 검토한 손실 함수들은 클래스 불균형이라는 공통의 문제를 해결하기 위해 각기 다른 철학과 메커니즘을 바탕으로 발전해왔다. 이들의 발전 과정을 요약하면, 가중치 부여 전략이 점차 정교하고 동적으로 변화하는 양상을 보인다.

- **1단계 (정적 클래스 기반):** WCE/BCE는 가장 기본적인 접근으로, 학습 전에 계산된 클래스 빈도 기반의 고정된 가중치를 사용한다.
- **2단계 (정교한 정적 클래스 기반):** Class-Balanced Loss는 '유효 샘플 수'라는 이론적 개념을 도입하여 정적 가중치 계산 방식을 더 정교하게 만들었다.
- **3단계 (동적 샘플 기반):** Focal Loss는 문제의 관점을 '클래스 불균형'에서 '쉬운/어려운 예제 불균형'으로 전환하고, 개별 샘플의 예측 확률에 따라 가중치를 동적으로 조절했다.
- **4단계 (동적 분포 기반):** GHM은 Focal Loss의 아이디어를 확장하여, 미니배치 내 전체 그래디언트 분포를 고려하여 가중치를 동적으로 조화시키는 더 일반화된 메커니즘을 제시했다.
- **5단계 (기하학적 마진 기반):** LDAM은 손실 값을 조정하는 기존의 패러다임에서 벗어나, 결정 경계의 마진을 직접 조절하는 기하학적 접근법을 도입하여 새로운 해결의 실마리를 제공했다.

이러한 발전 과정 속에서, 본 보고서에서 비교의 기준으로 삼는 "적응형 클래스 가중 교차 엔트로피 손실"은 1단계와 2단계 사이에 위치한다고 볼 수 있다. 즉, WCE/BCE와 같이 정적

클래스 기반 가중치 전략을 사용하지만, 로그 함수를 도입하여 BCE의 극단적인 가중치 할당 문제를 완화하려는 개선된 시도이다. 이는 CB Loss처럼 복잡한 이론적 배경이나 추가적인 하이퍼파라미터 없이, 더 단순하고 직관적인 방법으로 안정성을 높이려는 실용적인 접근법으로 평가될 수 있다.

향후 실험을 통해 제안된 함수의 효과를 검증할 때는 다음과 같은 질문에 답하는 방향으로 설계되어야 한다.

1. 제안된 함수는 극심한 불균형 상황에서 BCE보다 더 안정적인 학습을 유도하는가?
2. 제안된 함수는 CB Loss보다 구현이 간단하면서도 유사하거나 더 나은 성능을 보이는가?
3. Focal Loss나 LDAM과 같이 근본적으로 다른 접근법과 비교했을 때, 제안된 함수의 장점은 무엇이며 어떤 상황에서 더 유용할 수 있는가?

다음 표는 지금까지 논의된 주요 손실 함수들의 특징을 요약하여 비교한 것이다.

손실 함수 (Loss Function)	핵심 아이디어 (Core Idea)	가중치 전략 (Weighting Strategy)	주요 하이퍼파라미터 (Key Hyperparameters)	장점 (Pros)	단점 (Cons)
WCE / BCE	비용 민감 학습 / 클래스 빈도 역수 가중치	정적 - 클래스 기반	-	구현이 매우 간단하고 직관적임	극심한 불균형 시 소수 클래스에 과적합될 위험이 있음
Focal Loss	쉬운 예제의 손실을 줄여 어려운 예제에 집중	동적 - 샘플 기반	α, γ	쉬운/어려운 예제 불균형에 효과적, 높은 성능	최적의 성능을 위해 하이퍼파라미터 튜닝이 필요함
Class-Balanced Loss	데이터 중복을 고려한 유효 샘플 수 기반 가중치	정교한 정적 - 클래스 기반	β	강력한 이론적 기반, 다양한 손실 함수와 결합 가능	하이퍼파라미터 β 에 성능이 민감함
LDAM Loss	소수 클래스의 결정 경계 마진을 크게 설정	기하학적 마진 조정	C	Re-weighting과 직교하는 새로운 접근법, SOTA 성능	개념이 복잡하며, DRW와 같은 스케줄링과 함께 사용해야 최적 성능
GHM Loss	그라디언트 밀도를 통해 그라디언트 기여도 조화	동적 - 분포 기반	-	하이퍼파라미터 없이 데이터 분포에 적응, 이상치에 강건함	미니배치 단위 통계 계산으로 인한 약간의 오버헤드
제안된 손실 함수	로그 함수를 이용한 가중치 감소율 완화	정적 - 클래스 기반	-	하이퍼파라미터가 없어 단순함, BCE의 극단성 완화 가능성	이론적 기반이 상대적으로 약함, 동적 변화에 대응 불가