

데이터 분석

📅 시작일	@08/29/2025
📅 종료일	@09/06/2025
# 시작 값	0
# 종료 값	100
📊 진행 상황	0%
🕒 우선순위	높음
👤 담당자	고승호
⚙️ 상태	시작 전

프로젝트 정보

- Imbalanced data에 적합한 Data set 찾기. LLM, 학부연구생 선배들한테 물어보기.
- ML 방법을 여러 개로 선택했을 경우 나눠서 진행.

액션 아이템



북마크

Find Open Datasets and Machine Learning Projects | Kaggle

Download Open Datasets on 1000s of Projects + Share Projects on One Platform. Explore Popular Topics Like Government, Sports, Medicine, Fintech, Food, More. Flexible Data Ingestion.

[k https://www.kaggle.com/datasets](https://www.kaggle.com/datasets)

kaggle

UCI Machine Learning Repository

Discover datasets around the world!

<https://archive.ics.uci.edu/>

Data Set

▼ Binary Class

creditcardfraud

default+of+credit+card+clients

telco-customer-churn

breast+cancer+wisconsin+diagnostic

statlog+german+credit+data

secom

aps+failure+at+scania+trucks

bank+marketing

▼ Multi Class

glass+identification

steel+plates+faults

yeast

page+blocks+classification

covertypes

추천 데이터셋 목록

1. 신용카드 사기 탐지 (Credit Card Fraud Detection)

- **간단한 설명:** 유럽 카드 소지자들의 거래 데이터로, 정상 거래와 사기 거래를 분류하는 데이터셋입니다.
- **왜 이 연구에 적합한가?**
 - **극심한 불균형:** 전체 약 28만 건의 거래 중 사기 거래(소수 클래스)는 약 0.17%에 불과하여, 불균형 데이터 처리를 위한 손실 함수의 성능을 테스트하기에 가장 대표적이고 이상적인 데이터셋입니다.
 - **표준화된 피처:** 민감 정보를 보호하기 위해 모든 피처가 PCA 변환을 통해 익명화되어 있어 데이터 전처리가 용이합니다.
- **주요 특징:**
 - 총 샘플 수: 284,807개
 - 피처 수: 30개 (주로 PCA 변환 값)
 - 클래스 분포: 정상(99.83%) vs 사기(0.17%)
- **획득처:** [Kaggle Credit Card Fraud Detection Dataset](#)

2. 신용카드 채무 불이행 예측 (Default of Credit Card Clients)

- **간단한 설명:** 대만 신용카드사 고객들의 인구 통계 정보, 지불 상태, 청구 금액 등을 바탕으로 다음 달 채무 불이행(Default) 여부를 예측합니다.
- **왜 이 연구에 적합한가?**
 - **실용적인 불균형:** 금융권에서 실제로 발생하는 문제로, 채무 불이행 고객(소수 클래스) 비율이 약 22%로 현실적인 불균형을 다루고 있습니다.
 - **다양한 타입의 피처:** 수치형 데이터와 범주형 데이터가 혼합되어 있어 모델의 종합적인 성능을 평가하기에 좋습니다.
- **주요 특징:**
 - 총 샘플 수: 30,000개
 - 피처 수: 23개 (신용 한도, 성별, 교육 수준, 결혼 여부 등)
 - 클래스 분포: 정상 상환(78%) vs 채무 불이행(22%)
- **획득처:** [UCI Machine Learning Repository](#)

3. 통신사 고객 이탈 예측 (Telco Customer Churn)

- **간단한 설명:** 통신사 고객의 서비스 가입 정보, 인구 통계, 계정 정보 등을 바탕으로 고객의 이탈(Churn) 여부를 예측합니다.
- **왜 이 연구에 적합한가?**
 - **명확한 비즈니스 문제:** 고객 이탈은 많은 기업이 직면한 문제로, 소수 클래스(이탈 고객)를 정확히 예측하는 것이 중요합니다.
 - **범주형 데이터 다수 포함:** 범주형 변수가 많아 CatBoost와 같은 모델의 성능을 비교/분석하기에 적합합니다.
- **주요 특징:**
 - 총 샘플 수: 7,043개
 - 피처 수: 20개 (성별, 약정 기간, 인터넷 서비스 종류 등)
 - 클래스 분포: 유지(73.5%) vs 이탈(26.5%)
- **획득처:** [Kaggle Telco Customer Churn Dataset](#)

4. 유방암 진단 (Breast Cancer Wisconsin - Diagnostic)

- **간단한 설명:** 유방암 종양의 특징을 측정한 데이터를 바탕으로 종양이 악성(malignant)인지 양성(benign)인지를 분류합니다.
- **왜 이 연구에 적합한가?**

- **의료 분야의 대표 데이터셋:** 의료 분야는 데이터 불균형이 빈번하며, 특히 소수 클래스(악성)를 놓치지 않는 것이 매우 중요합니다.
- **적당한 불균형:** 불균형 비율이 극심하지 않아(약 2:1), 제안하는 손실 함수의 기본적인 성능과 안정성을 검증하기에 좋습니다.
- **주요 특징:**
 - 총 샘플 수: 569개
 - 피쳐 수: 30개 (반경, 질감, 둘레, 면적 등)
 - 클래스 분포: 양성(62.7%) vs 악성(37.3%)
- **획득처:** [UCI Machine Learning Repository](#)

5. 독일 신용 데이터 (Statlog - German Credit Data)

- **간단한 설명:** 독일 은행 고객들의 데이터를 바탕으로 신용 위험도를 ' 좋음' 또는 '나쁨'으로 분류합니다.
- **왜 이 연구에 적합한가?**
 - **전통적인 벤치마크:** 오랫동안 머신러닝 분류 문제의 벤치마크로 사용되어 온 데이터셋으로, 다른 연구들과의 성능 비교가 용이합니다.
 - **비용 민감성:** 소수 클래스인 '나쁨' 신용도를 가진 고객을 ' 좋음'으로 잘못 판단할 경우 발생하는 비용이 크기 때문에, 손실 함수 연구에 적합한 맥락을 가집니다.
- **주요 특징:**
 - 총 샘플 수: 1,000개
 - 피쳐 수: 20개 (계좌 상태, 신용 기록, 직업 등)
 - 클래스 분포: 좋음(70%) vs 나쁨(30%)
- **획득처:** [UCI Machine Learning Repository](#)

6. 반도체 제조 공정 불량 예측 (SECOM Data Set)

- **간단한 설명:** 반도체 제조 공정 중 센서들로부터 수집된 신호 데이터를 바탕으로 제품의 불량 여부를 예측합니다.
- **왜 이 연구에 적합한가?**
 - **높은 불균형도와 결측치:** 불량품(소수 클래스)의 비율이 매우 낮고, 실제 산업 데이터처럼 결측치가 많아 손실 함수가 얼마나 강건하게 작동하는지 테스트하기에 좋습니다.

- **고차원 데이터:** 피처의 수가 590개로 많아, 고차원 데이터 환경에서의 성능을 검증해 볼 수 있습니다.
- **주요 특징:**
 - 총 샘플 수: 1,567개
 - 피처 수: 590개 (센서 측정값)
 - 클래스 분포: 정상(93.2%) vs 불량(6.8%)
- **획득처:** [UCI Machine Learning Repository](#)

7. APS 고장 예측 (APS Failure in Scania Trucks)

- **간단한 설명:** 스카니아(Scania) 트럭의 핵심 부품인 공기압 시스템(Air Pressure System, APS)의 고장 여부를 예측하는 데이터셋입니다.
- **왜 이 연구에 적합한가?**
 - **극심한 불균형:** 고장(소수 클래스)은 전체 데이터의 약 1.7%에 불과하여, 매우 드물게 발생하는 이벤트를 탐지하는 손실 함수의 성능을 측정하기에 적합합니다.
 - **높은 비용 민감성:** 실제 산업 문제에서 고장을 예측하지 못했을 때의 비용은 매우 크므로, 재현율(Recall)을 높이는 손실 함수의 중요성을 부각할 수 있습니다.
 - **다수의 결측치:** 실제 산업 데이터처럼 결측치가 다수 포함되어 있어, 강건한(robust) 모델 및 손실 함수를 테스트하기에 좋은 환경을 제공합니다.
- **주요 특징:**
 - 총 샘플 수: 76,000개 (학습 60,000, 테스트 16,000)
 - 피처 수: 170개 (익명화된 센서 데이터)
 - 클래스 분포: 정상(98.3%) vs 고장(1.7%)
- **획득처:** [UCI Machine Learning Repository](#)

8. 은행 마케팅 예측 (Bank Marketing)

- **간단한 설명:** 포르투갈 은행의 전화 마케팅 캠페인 데이터를 기반으로, 고객이 정기 예금에 가입할지 여부를 예측합니다.
- **왜 이 연구에 적합한가?**
 - **현실적인 비즈니스 문제:** 고객 확보라는 명확한 비즈니스 목표를 가진 데이터로, 소수 클래스(가입 고객) 예측의 실용적인 가치를 평가할 수 있습니다.
 - **혼합된 데이터 타입:** 고객의 나이, 직업, 결혼 여부 등 수치형과 범주형 피처가 혼합되어 있어 모델의 종합적인 처리 능력을 볼 수 있습니다.

- **주요 특징:**
 - 총 샘플 수: 45,211개
 - 피처 수: 16개 (나이, 직업, 주택 대출 여부 등)
 - 클래스 분포: 미가입(88.3%) vs 가입(11.7%)
- **획득처:** [UCI Machine Learning Repository](#)

9. 유리 식별 (Glass Identification)

- **간단한 설명:** 유리의 화학 성분(굴절률, 나트륨, 마그네슘 등)을 기반으로 해당 유리의 유형을 분류하는 다중 클래스 데이터셋입니다.
- **왜 이 연구에 적합한가?**
 - **대표적인 다중 클래스 문제:** 2개가 아닌 여러 개의 클래스를 분류하는 문제로, 다중 클래스용으로 설계된 손실 함수의 성능을 직접적으로 평가할 수 있습니다.
 - **클래스 간 불균형:** 각 유리 유형의 샘플 수가 불균등하여, 다중 클래스 환경에서의 불균형 처리 능력을 검증하기에 적합합니다.
- **주요 특징:**
 - 총 샘플 수: 214개
 - 피처 수: 9개 (화학 성분)
 - 클래스 분포: 6개 유형 (창문, 차량용, 식기류 등)
- **획득처:** [UCI Machine Learning Repository](#)

10. 강판 불량 유형 분류 (Steel Plates Faults)

- **간단한 설명:** 강판 표면의 기하학적 특징들을 측정하여 7가지 유형의 불량 중 어떤 것에 해당하는지 분류합니다.
- **왜 이 연구에 적합한가?**
 - **산업 도메인의 다중 클래스 문제:** 제조업 분야의 품질 관리(QC)와 직접적으로 관련된 문제로, 각 불량 유형을 정확히 식별하는 능력을 평가할 수 있습니다.
 - **명확한 피처:** X, Y 좌표, 면적 등 물리적 측정이 완료된 피처로 구성되어 있어 해석이 용이합니다.
- **주요 특징:**
 - 총 샘플 수: 1,941개
 - 피처 수: 27개 (결함의 기하학적 특징)

- 클래스 분포: 7개 불량 유형 (Pastry, Z_Scratch, Bumps 등)
- 획득처: [UCI Machine Learning Repository](#)

11. 효모 단백질 세포 위치 예측 (Yeast)

- **간단한 설명:** 아미노산 서열 등 생화학적 특징을 바탕으로 효모 단백질이 세포 내 10곳의 위치 중 어디에 분포하는지 예측합니다.
- **왜 이 연구에 적합한가?**
 - **심한 불균형의 다중 클래스 문제:** 10개의 클래스가 매우 불균등하게 분포하여(가장 많은 클래스는 31%, 가장 적은 클래스는 0.3%), 다중 클래스 손실 함수의 성능을 극한의 환경에서 테스트할 수 있습니다.
 - **생물정보학 벤치마크:** 생물정보학 분야에서 자주 사용되는 고전적인 벤치마크 데이터셋입니다.
- **주요 특징:**
 - 총 샘플 수: 1,484개
 - 피처 수: 8개 (생화학적 측정값)
 - 클래스 분포: 10개 세포 위치 (세포질, 핵, 미토콘드리아 등)
- 획득처: [UCI Machine Learning Repository](#)

12. 웹 페이지 블록 분류 (Page Blocks Classification)

- **간단한 설명:** 문서 이미지의 각 블록이 텍스트, 수평선, 그림 등 5가지 유형 중 어떤 유형에 속하는지 분류합니다.
- **왜 이 연구에 적합한가?**
 - **극심한 클래스 불균형:** 다수 클래스인 '텍스트'가 전체의 약 90%를 차지하여, 다른 소수 클래스들을 얼마나 잘 분류해내는지 평가하기에 좋은 데이터셋입니다.
- **주요 특징:**
 - 총 샘플 수: 5,473개
 - 피처 수: 10개 (블록의 높이, 너비, 여백 등 기하학적 특징)
 - 클래스 분포: 5개 유형 (텍스트, 수평선, 그림, 수직선, 그래픽)
- 획득처: [UCI Machine Learning Repository](#)

13. 산림 피복 유형 예측 (Cover Type)

- **간단한 설명:** 미국 콜로라도의 특정 지역의 지도 데이터(고도, 경사, 토양 유형 등)를 사용하여 해당 지역의 나무 피복 유형을 7가지로 예측합니다.
- **왜 이 연구에 적합한가?**
 - **대용량 다중 클래스 데이터셋:** 샘플 수가 58만 개 이상으로 매우 커서, 대용량 데이터에서도 손실 함수가 안정적으로 동작하고 모델이 잘 일반화되는지 확인할 수 있습니다.
 - **다양한 피처 조합:** 수치형 피처와 이진(binary) 형태의 토양 유형 피처가 혼합되어 있습니다.
- **주요 특징:**
 - 총 샘플 수: 581,012개
 - 피처 수: 54개 (고도, 경사, 토양 유형, 그림자 등)
 - 클래스 분포: 7개 나무 유형 (가문비나무/전나무, 로지폴 소나무 등)
- **획득처:** [UCI Machine Learning Repository](#)